

정확도 조사 리포트 — 2026-09-17 ~ 09-18

공개 정확도 수치를 갱신하려다 시작해서, 백테스트 자체의 결함 3건을 찾아 고치고, 엔진의 기여가 어디에 있는지를 처음으로 분리해 낸 작업의 기록.

결론부터:

- 1. 공개 중인 top-2/top-3는 브랜드를 전혀 모르는 기준선과 같은 수준이다. 수치 자체는 정직하지만 엔진의 기여를 보여주지 못한다.
- 2. 엔진의 기여는 "정답이 뻔하지 않은 건"에 몰려 있다. 그 19건에서 1순위 42%·3순위 79%(무작위 11%·33%).
- 3. 시뮬레이션과 기준선이 일치하는지 여부가 이 조사에서 유일하게 두 번 재현된 신호다. 이걸 제품에 반영했다.
- 4. 홈페이지는 아직 바꾸지 않았다. 로컬 커밋만 있고 푸시하지 않았다.

1. 고친 결함

1-1. as-of 날짜를 모델에게 알려준 적이 없었다 (679dfc6)

`projectInput.asOfDate` 는 줄곧 존재했지만 읽는 곳은 `prefetch.ts` 뿐이었다(Comtrade 기간, 관세 앵커 게이팅). `prompts.ts` 에는 참조가 0곳. 모델은 2026년에 앉아 결과를 다 아는 채로, 시점에 맞는 무역 데이터만 첨부받아 답해 왔다. 그걸 "hindsight-controlled"라고 불러 왔다.

- `countryPrompt` · `personaPrompt` 가 `asOfDate` 가 있을 때만 as-of 블록을 렌더한다.
- 두 가지를 요구: ①그 시점 시장 조건으로 판단 ②브랜드의 후일 결과가 기억나도 근거가 아니며 역산 금지.
- 라이브 무영향 확인: 양쪽으로 렌더해 블록이 라이브 프롬프트에 없음을 검증(`scripts/_asof-render.ts`).

측정 결과: 효과 없음. 지시문을 넣어도 점수가 떨어지지 않았다(top-1 63%, 이전 61%). 모델은 자기 지식에 날짜표가 없어 무엇이 이후 정보인지 스스로 가르치 못한다. "2016년인 척하라"로는 회상을 막을 수 없다는 것이 실측으로 확인됐다.

1-2. 사전 웹 검색이 브랜드명 + 현재 연도로 검색하고 있었다 (a93c745)

관세·거버넌스·소셜버즈·GTM 탐색에는 as-of 가드가 있었는데 Tavily 검색 3종에는 없었다.

- 트렌드 쿼리: `food consumer trends 2025 2026 ... regional growth {브랜드명}`
- 한국어판: `... 해외 진출 수출 매출 ... {브랜드명}` / 일본어판: `... 海外展開 輸出 {브랜드명}`
- Shake Shack 실측: 결과 5건 전부 "2026 성장 전략"류 현재 기사.

2026-05-10 도입 이후 모든 백테스트(공개 수치 기준인 09-13 실행 포함)에 해당. 결과는 페르소나 프롬프트와 가격 단계로 들어갔다. KOL 검색은 브랜드명을 의도적으로 제외하고 있었으나 현재 연도를 쓰고 국가 순위 프롬프트로 직접 들어간다.

1-3. 페르소나 풀이 시대를 섞고 있었다 (a93c745)

풀은 (국가, 직업)으로만 키를 잡아 언제 만들어진 페르소나인지 개념이 없다. 2021년 픽스처용 페르소나가 1968년 픽스처에 재사용된다. as-of 실행 실측: 26,400 슬롯 중 32%가 풀 재사용 — 패널 3분의 1이 다른 시대였다.

두 결함 모두 asOfDate 가 있으면 꺼진다. 검증: 같은 입력으로 as-of는 trend/margin/KOL = 0/0/0, 라이브는 9/5/5. 백테스트 로그에 pool: 0 hits / 200 misses 확인.

수정 후 점수는 떨어지지 않았다(61/76/84 → 61/76/84). 누출이 수치를 부풀리고 있던 것은 아니었다.

2. 회상(암기) 문제 — 이 코퍼스의 구조적 한계

측정한 것

실험	결과
이름만 주고 맞추기 (Sonnet 4.6, 3샘플)	31/42 (74%), 41/42 만장일치
모델이 모르는 건에서 엔진 top-1	45~50% (블라인드 73~80%보다 낮음)
익명화 15건 실행	엔진 top-1 53% → 40% (블라인드와 동일)
익명화해도 브랜드 식별됨	25/42가 3/3 식별

핵심 발견

브랜드명을 지우고 특징적 디테일까지 3라운드에 걸쳐 일반화해도 42건 중 27건은 모델이 브랜드를 맞힌다. "뉴질랜드의 클라우드 회계 플랫폼" → Xero, "미국의 스트리밍 구독" → Netflix. 카테고리+원산지+포지셔닝만으로 식별된다.

원인은 익명화 실패가 아니라 코퍼스 선정 방식이다. 백테스트 픽스처는 결과가 문서화된 브랜드여야 하고, 문서화된 성공 사례는 모델도 학습했다. 유명할수록 정답이 확실하고, 유명할수록 모델이 안다.

익명화 15건(식별 불가 건만)에서 top-1은 53%→40%로 떨어졌지만 top-3는 73%→80%로 떨어지지 않았고 평균 순위도 2.40으로 동일했다. 회상은 1위 선택에 몰려 있고, 후보군 품질은 브랜드 정체 없이도 유지된다.

3. 최종 측정 (누출 수정 후, 42건)

top-1 60% · top-2 76% · top-3 83% (\$93.51, 2시간 41분, 42/42 완주)

블라인드 기준선과 비교 (N=39)

	top-1	top-2	top-3	평균순위
엔진(수정 후)	61%	76%	84%	1.97
블라인드 전체순위	51%	76%	84%	2.18

top-2·top-3가 동일. 엔진이 앞서는 건 top-1(+8pp, 8승5패, p=0.58)과 평균순위뿐이고 미판정.

난이도로 나누면 (블라인드가 1위를 틀린 건 = 어려움)

	엔진 top-1	top-2	top-3
어려운 19건	42%	63%	79%
무작위 기대	11%	22%	33%
쉬운 20건	75%	90%	90%

쉬운 20건에서는 오히려 5건을 놓쳤다(CHAGEE·Krating Daeng·Mixue·Netflix·Paris Baguette). 전체 합계가 기준선과 같아지는 이유가 이것이다.

4. 제품 변경 (51de3ac)

결합 방식 검증

규칙	적중	평균 추천 수
고정 엔진 top-2 (기준)	77%	2.00
적응형: 일치→1곳 / 불일치→3곳	82%	1.90
목록 병합(엔진1위+블라인드1위)	72%	2.00

목록을 합치는 건 나쁘다 — 블라인드 1위가 대개 엔진 top-2 안에 이미 있어 칸을 낭비한다.

일치 신호 (두 번 재현)

실행	일치 시 적중	불일치 시	p
run G	79% (15/19)	33% (7/21)	0.0051
수정 실행	79% (15/19)	40% (8/20)	0.0225

불일치일 때 블라인드도 25%로 낮다 — "다른 쪽이 맞다"가 아니라 "둘 다 못 믿는다"는 뜻.

적용한 것

- 교차검증 기본값 ON (SIM_BLIND_CROSSCHECK=off 로 끄)
- 일치 → 1곳 추천 / 불일치 → 3곳(엔진 top-2 + 기준선 픽) + shortlist 필드
- 결과 화면에 교차검증 배너 (일치=초록 / 불일치=주황)
- 기존 양상블은 crossCheck 필드가 없어 이전과 동일하게 표시

5. 계측 복구 (미커밋)

11m_usage_log 는 2026-05-29 이후 기록이 없었다. 원인: 시뮬레이션 파이프라인이 usageContext 를 한 번도 넘기지 않아, API 라우트가 주변 컨텍스트를 걸어준 경우에만 기록됐다. 백그라운드·CLI 실행은 전부 누락.

- `runner.ts` : 프로바이더 생성 전에 워크스페이스를 조회해 4개 단계 전부에 `usageContext` 부착
- `smoke-ensemble-e2e.ts` : CLI에서도 로거가 등록되도록 side-effect import (Next.js `instrumentation.ts` 는 스크립트에서 안 돈다)
- 가격 단계 토큰 로그 추가 — 유일하게 계측이 없던 단계

가격 단계 실측: 5샘플 기준 입력 18,360 / 출력 2,257 토큰 → 시물당 \$0.023, 시장 1개 추가당 약 \$0.07(hypothesis 3시물 기준). 3곳 추천이면 앙상블당 +\$0.14, 원가의 약 5%.

6. 비용

항목	금액
as-of 지시문 검증 실행 (42건)	\$101.00
익명화 실행 (15건)	\$35.19
누출 수정 후 재실행 (42건)	\$93.51
가격 계측 (1건)	~\$2.40
프로브류(이름만·블라인드·익명화 생성)	~\$5
합계	약 \$237

7. 홈페이지 상태

아직 반영하지 않았다. 별도 저장소(`markettwin-web`)에 로컬 커밋 2개(`841e8c7` , `4a6b083`)가 있고 푸시하지 않았다. 공개 페이지는 여전히 Top-2 68% / Top-3 74%.

`proposals/` 의 IR 문서는 hindsight 문구를 "시점 통제(부분)"로 정정했으나 요청에 따라 커밋하지 않았다 (작업 트리에만 존재).

8. 미해결

- 공개 수치를 어떻게 쓸지 미정. 76/83으로 올릴지, 68/74를 유지할지, 난이도 프레이밍으로 갈지.
- 적응형 규칙은 사후 선택. 82% vs 77%는 2건 차이(2승 0패, $p=0.50$). 다음 코퍼스에서 규칙을 먼저 동결하고 재검증해야 한다.
- 블라인드 기준선이 형식에 민감하다. 같은 15건에서 단일픽 40% vs 순위 27%. 기준선 수치를 단정적으로 인용하면 안 된다.
- 블라인드 순위 3건 생성 실패 — 해결(파서가 자기수정 JSON을 못 읽던 문제, 9-2 참조). 42건 전부 확보.
- `0xC0000409` 네이티브 크래시 — 실행당 5% 내외, 재시도로 회수 중. 원인 미규명.

9. 오늘부로 공개할 수치

9-1. 헤드라인

> 42개 브랜드 백테스트(2026-09-17 측정, 42건 전건 채점) — 추천 2곳 안에 실제 승리 시장 76%, 3곳 안에 83%

지표	값
top-1 (단일 확정 추천)	60% (25/42)
top-2 (제품이 보여주는 shortlist)	76% (32/42)
top-3	83% (35/42)

산출 방법

- 1. 브랜드마다 실제 해외 진출 결정 시점으로 되돌린다(1968~2021년, 브랜드별 상이).
- 2. 무역(UN Comtrade)·거시(World Bank) 앵커를 그 시점으로 컷오프한다. 관세·거버넌스 지수·소셜버즈·브랜드 웹검색은 현재 데이터이므로 끈다.
- 3. 3개 LLM(Anthropic·OpenAI·DeepSeek) × 각 200 페르소나로 앙상블을 돌린다. 페르소나는 as-of 시점 기준으로 새로 생성한다(풀 재사용 없음).
- 4. 국가 순위는 Sonnet 4.6이 5회 샘플링한 값의 중앙값으로 정한다.
- 5. 원산지는 순위에서 제외한다(한국 브랜드에 한국이 1위로 잡히는 것을 막는다).
- 6. 정답이 지원 24개 시장 밖이면 채점에서 제외한다.
- 7. 정답 정의는 "첫 진입"이 아니라 첫 지속·최대 해외시장이다.

이전 수치(68/74)와 다른 이유 — 코퍼스가 19건에서 42건으로 늘었고, 실행 일자가 다르며, 무엇보다 백테스트 결함 3건(2절)을 고친 뒤의 값이다. 누출 수정 자체는 점수를 바꾸지 않았다(61/76/84 → 61/76/84).

9-2. 기준선 대비 — 내부 판단용 (공개문에는 넣지 않기로 결정)

브랜드명과 설명문을 전혀 주지 않고 카테고리화 원산지만으로 후보국 전체 순위를 매기게 한 기준선(Sonnet 4.6, 3샘플 평균순위), 세 실행 공통 41건:

N=41	top-1	top-2	top-3	평균순위
엔진(수정 후)	61%	76%	83%	2.07
기준선	51%	76%	83%	2.27

top-2·top-3는 동물이다. 헤드라인 숫자만으로는 엔진의 기여가 증명되지 않는다. 공개문에 넣지 않기로 했으나, 대외 질의가 들어오면 이 표가 답이다. 내부적으로 잊지 말 것.

(기준선이 3건에서 순위를 못 만들던 문제는 해결됐다. 모델이 후보 밖 코드를 쓴 JSON을 먼저 내고 "제공된 코드만 써야 한다"고 적은 뒤 고친 JSON을 다시 내는데, 파서가 첫 { 부터 마지막 } 까지를 한 덩어리로 잡아 산문까지 삼켰다. 개별 객체를 훑어 마지막 유효본을 쓰도록 고쳐 42건이 모두 채워졌다.)

9-3. 엔진의 기여가 나타나는 곳

난이도를 기준선이 1위를 틀린 건 = 어려움으로 정의하면 42건이 정확히 반으로 갈린다.

	엔진 top-1	top-2	top-3
어려운 21건	43%	62%	76%
무작위 기대	11%	22%	33%
쉬운 21건	76%	90%	90%

쉬운 21건에서는 오히려 5건을 놓쳤다(CHAGEE·Krating Daeng·Mixue·Netflix·Paris Baguette). **전체 합계가 기준선과 같아지는 이유가 이것이다.** 공개 문구는 이 구조를 그대로 말하는 편이 정확하다 — **"카테고리와 원산지만으로 답이 나오는 건은 시뮬레이션이 필요 없습니다."***

9-4. 제품이 실제로 하는 일

수치가 나온 절차가 곧 제품의 동작이다.

- **1. 페르소나 200명 생성** — 후보 시장별로 직업·소득 구간을 배분해 생성하고, 각자의 구매 의향·가격 민감도·반대 이유·신뢰 요인을 받는다.
- **2. 국가 순위** — 페르소나 통계에 무역·거시 앵커를 얹어 후보국을 점수화한다. 5회 샘플링 후 중앙값으로 수렴시킨다(1회로는 ±33점까지 흔들린다).
- **3. 앙상블** — 서로 다른 3개 LLM이 독립적으로 같은 작업을 하고, 국가별 점수를 합산한다.
- **4. 브랜드를 가린 교차검증** — 같은 카테고리·원산지를 브랜드 없이 물어 별도의 답을 받는다(3샘플 다 수결).
- **5. 추천 폭 결정** — 두 답이 **일치하면 1곳**으로 좁혀 추천하고, **갈리면 3곳**(엔진 top-2 + 기준선 픽)으로 넓히며 신뢰도를 한 단계 낮춘다.
- **6. 시장별 가격 곡선** — 추천된 각 시장마다 가격·전환율 곡선과 추천가를 따로 산출한다.
- **7. 결과 화면** — 일치/불일치를 배너로 표시하고, 시장마다 수요·경쟁·CAC·주요 반대 이유·신뢰 요인을 붙인다.

4~5단계의 근거

실행	일치 시 적중	불일치 시	p
run G (2026-09-16)	79% (15/19)	33% (7/21)	0.0051
누출 수정 실행 (09-17)	76% (16/21)	43% (9/21)	0.058

불일치일 때는 기준선도 24%로 낮다 — **"다른 쪽이 맞다"**가 아니라 **"둘 다 못 믿는다"**는 뜻이므로 좁히지 않는 것이 맞다. **방향은 두 실행에서 재현됐고, 유의성은 두 번째 실행에서 경계선에 걸친다**(파서를 고쳐 3건이 추가되자 p가 0.0225에서 0.058로 올라갔다). 인용할 때 **"재현됐다"**까지는 되지만 **"유의하다"**까지는 아니다.

42건 기준	적중	평균 추천 시장 수
적응형(일치→1곳 / 불일치→3곳)	81% (34/42)	1.88
고정 2곳 (기존 제품)	76% (32/42)	2.00
고정 3곳	83% (35/42)	3.00

적응형은 추천을 더 적게 하면서 더 많이 맞힌다. 고정 3곳과 비교하면 같은 83%에 근접하면서 추천 시장을 1.1곳 덜 준다.

9-5. 공개문에 함께 적어야 할 한계

- 코퍼스가 유명 브랜드 중심이다. 모델은 브랜드명만 줘도 74%를 맞힌다. 이 수치는 예측력만큼 회상을 재고 있다.
- 기준선은 질문 형식에 민감하다. 같은 15건에서 단일 선택 40% vs 순위 방식 27%.
- 표본이 작다. 42건에서 1건은 2.4%p다.

9-6. 쓰지 말아야 할 것

- 68/74 유지 — 더 작고 오래된 표본이며, 그 실행에도 동일한 누출이 있었다.
- "경쟁사보다 정확하다" — 근거 없음.
- "hindsight-controlled" — 사실이 아니다(제거 완료).
- 난이도 구분 없이 76/83만 강조 — 기준선과 동률이라 반박당한다.

9-7. 결정 사항 (2026-09-18)

- 기준선 동률(9-2)은 공개문에 넣지 않는다. 강조를 고르는 문제이므로 생략 가능하다. 다만 내부적으로는 알고 있어야 하고, 대외 질의가 오면 9-2 표로 답한다.
- 적응형 81%는 공개한다. 제품이 실제로 그렇게 동작하며(51de3ac), 헤드라인과 같은 42건 기준이다.
- 사후 선택·2건 차이 문구는 넣지 않는다. 단 규칙을 데이터 보고 고른 것은 사실이므로, 다음 코퍼스에서 규칙을 먼저 동결하고 재검증한다(10절).

9-8. 적용된 공개 문구

홈페이지(markettwin-web) index.html · index-en.html · deck.html · singapore-plan.html · case-study.html 에 반영했다. 로컬 커밋 상태이며 아직 푸시하지 않았다.

> 글로벌 42개 브랜드 backtest — 추천 shortlist에 실제 승리 시장 포함률 **Top-2 76% · Top-3 83%** (2026.09 측정, 42건 전건 채점). 시뮬레이션과 브랜드를 가린 판단이 일치하면 한 곳으로 좁혀 추천하고, **갈리면 넓혀서 제시합니다** — 평균 1.9곳 추천으로 **81% 적중**.

무작위 대비 배수는 평균 후보 9.3개 기준 top-2 기대치 21.5%에 대해 **3.5배**로 정정했다(이전 표기 3.6배는 코퍼스가 바뀌기 전 값).

10. 다음 단계

- 1. 전향적 코호트 첫 확인 — 2026-10. 15건 예측이 2026-07-06에 동결돼 있고 DB와 문서가 정확히 일치함을 확인했다. 회상 오염이 원천적으로 없는 유일한 근거.

- 2. 무명 중소기업 코퍼스 — KOTRA 기업성공사례 API(275건, 무료, 키 보유)에서 소비재 96건이 후보. 기업별 국가별 수출실적은 관세법 116조로 공개 조회 불가하므로 정답은 다중 증거로 확정해야 한다.
- 3. 적응형 규칙 사전등록 후 재검증.