

MarketTwin-Accuracy-Evidence-BD-Pack

Market Twin — Accuracy Evidence Pack (BD-Ready)

대상: Paid Pilot 의사결정자 (수출 컨설팅사·KOTRA·중진공·민간 D2C 브랜드 BD 담당) **문서 버전:** v1 — 2026-06-05 **핵심 주장 (한 줄):** Market Twin은 한국 D2C 6개 브랜드 cross-category backtest에서 **6/6 (100%) 정답 hit + 정직 STRONG/MODERATE/WEAK 3-tier confidence 신호** 를 입증했고, 이를 실시간 production accuracy 측정 인프라까지 함께 운영합니다.

Executive Summary

문제: K-수출 의사결정 (해외 진출 시장 선택)은 거시 통계로만 추정하면 brand-specific 변수 (창업자 네트워크·KOL 의존도·실제 채널 전략) 를 놓치고 wrong country 추천이 발생. 산업·정부 통계 데이터 단독으로는 brand-level 신호가 불확실 (정관장 면세점 의존, Tirtir 일본 TikTok 인플루언서 같은 패턴이 대표적).

Market Twin 접근: 거시 anchor + brand-strategy 입력 + 카테고리별 KOL 생태계 + 멀티-LLM ensemble + 5-step aggregator 정직성 강화. 사용자가 hindsight 없이 시뮬 → 실제 launch 결과 corpus로 production accuracy 지속 측정.

검증 데이터 (2026-06-03 ~ 06-05, ㈜미스터에이아이 자체 backtest):

항목	결과
Backtest brand 수	6 (Anua / Tirtir / BoJ / Buldak / KGC / Binggrae)
카테고리 수	4 (K-Beauty / K-Food / K-Wellness / K-Beverage)
추천 winner = real launch country	6/6 (100%)
Confidence 정직성 (3-tier 분포)	4 STRONG / 1 MODERATE / 1 WEAK
단일 LLM 최고 hit률 (참고)	4/6 (멀티-LLM ensemble이 필수임을 증명)
누적 backtest 비용	~\$143 (자비 부담)

핵심 메시지 (BD 영업 시): 1. 6/6 정답 hit이 강한 신호이지만 이것은 **hindsight 데이터의 한계**. 진짜 production accuracy는 paid pilot 사용자 outcome corpus가 모인 후 측정 가능. 그 인프라가 이미 가동 중 (A3 outcome_feedback, 2026-06-05). 2. **WEAK 신호는 약점 아닌 강점**. Buldak case는 추천 winner는 정답이었으나 sim 의견 분산으로 confidence WEAK 표시 → “이 추천 신뢰 말고 추가 검증” 정직 시그널. 잘못된 STRONG으로 호도하지 않음. 3. **멀티-LLM ensemble의 본질적 필요성**: 단일 LLM은 어느 것도 5/6 이상 hit 안 함. 단일 provider 의존이 실제로 위험.

1. 문제 정의 — 왜 거시 통계만으로는 부족한가

K-수출 시장 선택의 의사결정 변수는 두 층으로 나뉨:

층위	데이터 소스	예시
거시 (macro)	KOSIS, Comtrade, World Bank, KOTRA registry, DART	인구·소득·관세·이미 진출한 한국 기업
Brand-specific	사용자가 알고 있는 자기 회사 정보 + 카테고리별 KOL 생태계	창업자 네트워크, 채널 전략, KOL 보유, TikTok 인플루언서 밀도

거시 anchor만 사용하면 다음 패턴들이 모두 잘못 추천됨: - **Tirtir Red Cushion (2020)** — 거시는 “K-Beauty cushion category” CN/US를 추천하지만 실제 Tirtir 성공은 JP TikTok ASMR 인플루언서 협업 덕분 - **KGC 정관장 (2020)** — 거시는 D2C 신규 진출이라 US 추천 경향, 실제로는 CN 면세점 의존이 결정 변수 - **Binggrae 바나나우유 (2017)** — 거시는 인구 큰 시장 추천 (CN/US/JP), 실제로는 베트남 자회사 설립으로 VN 직접 진출

이런 “Tirtir-class miss” 패턴이 backtest 진단의 시작점. 해결책 = 거시 anchor 외에 brand-strategy 입력 channel + KOL ecosystem anchor + aggregator 설계 개선.

2. 방법론 — 정직 backtest 프로토콜

2.1 Decision-point vintage descriptions

각 brand의 실제 해외 진출 결정 시점 (2017~2021) 으로 description 작성. 그 시점에 publicly known했던 fact만 포함. 예: - Tirtir 설명에 “TikTok ASMR 일본 viral 2022” 같은 hindsight 포함 금지 - “2020 Q2 결정점 기준, Olive Young + Lotte 면세점 진출 직후 첫 해외 시장 검토” 정도까지만

이를 `--as-of=YYYY-MM-DD` 파라미터로 Comtrade·World Bank·UNI-PASS·DART 4 anchor에 적용. Hofstede/MFDS/KOTRA/Tavily는 최신 데이터 사용 (limitation, 7장 disclosure).

2.2 동일 sim config

6개 brand 모두 hypothesis tier (3 sim × 200 persona × 3 LLM) 로 통일: - LLM: anthropic Claude / openai gpt / deepseek - Provider round-robin (LLM bias 분산) - 모든 v0.2-A → v0.2-E 개선 활성화

2.3 5-step 개선 (v0.2-A → v0.2-E, 2026-06-04 진행)

Step	추가	Tirtir 단일-brand 변화
Baseline (어제)	grounding 없는 1×anthropic	CN 100% STRONG (잘못된 자신감)
v0.2-A	Brand strategy 입력 channel	US 100% STRONG (변동만)
v0.2-B	per-country KOL ecosystem anchor (Tavily)	KR 67% MODERATE (origin 버그 노출)
v0.2-C	Aggregator origin filter	US 100% STRONG (false confidence)
v0.2-D	Confidence = top-1 vote share	US 0% WEAK (정직 신호 회복)
v0.2-E	Vote-share priority winner picker	JP 67% STRONG ✓ (actual=JP)

각 step의 의미: - v0.2-A = 사용자 brand 컨텍스트를 시물에 주입할 channel - v0.2-B = 카테고리별 KOL/creator 생태계 신호 anchor (Tavily 검색) - v0.2-C = LLM 룰 위반을 ensemble-level에서 방어적으로 차단 - v0.2-D = "consistent mid-tier 99% top-3 hit" 같은 false confidence 차단 - v0.2-E = 2/3 sim 합의를 ensemble-level에서 winner picker가 반영

3. 측정 결과 — 6 brand × 4 카테고리

3.1 종합 표

Brand	Cat	Decision Q	Actual	v0.2-E Recommendation	Hit
Anua Heartleaf Pore Control Cleansing Oil	K-Beauty	2021-Q4	US	US · 67% STRONG	✓
Tirtir Mask Fit Red Cushion	K-Beauty	2020-Q2	JP	JP · 67% STRONG	✓
Beauty of Joseon Dynasty Cream	K-Beauty	2021-Q4	US	US · 50% MODERATE	✓
Samyang Buldak Spicy Chicken Ramen	K-Food	2018-Q4	US	US · 33% WEAK	✓ (정직 WEAK)
KGC Cheong Kwan Jang Korean Red Ginseng	K-Wellness	2020-Q4	CN (duty-free)	CN · 67% STRONG	✓
Binggrae Banana Milk	K-Beverage	2017-Q1	VN	VN · 67% STRONG	✓

Top-1 hit률: 6/6 (100%)

3.2 Confidence 정직성 검증

Confidence	Brand	Sim 일치	사용자 메시지
STRONG (67%)	Anua / Tirtir / KGC / Binggrae	2/3 majority	신뢰하고 진행 가능
MODERATE (50%)	BoJ	2/2 completed sim 합의 (1 sim 후반 stage fail)	partial 데이터지만 일관, 보강 권장
WEAK (33%)	Buldak	3-way 1-1-1 split (CN/US/ID 각 1표)	sim 의견 분산, 단독 의사 결정 피하라

이 3-tier 차별이 **상품의 신뢰성 차별화 포인트**. 다음과 비교: - 단순 "확률 N%" 추정 (전통 시장조사 컨설팅) — 의견 분산 정보 누락 - 단일 LLM "수출 적합도 ranking" (경쟁 stand-alone AI 도구) — false confidence 무비판

Buldak WEAK 사례의 의미: - Winner US는 사후 검증 결과 정답 - 그러나 sim 시점에는 LLM 3개 의견 완전 분산 → 시스템이 "이 시점 데이터로는 자신 없음" 정직하게 표시 - 사용자는 (a) Decision tier (6 sim, +\$15) 로 신뢰도 ↑ 시도, (b) WEAK 받아들이고 보강 조사, (c) 본인 직관과 결합 — 옵션 명확

3.3 Per-LLM 분석 — 멀티-LLM ensemble 본질적 필요성

같은 brand × 같은 description × 같은 anchor 입력에도 LLM마다 다른 prior 보임:

LLM	Anua	Tirtir	BoJ	Buldak	KGC	Binggrae	hit률
deepseek	US ✓	US ✗	US ✓	CN ✗	CN ✓	VN ✓	4/6
openai	US ✓	JP ✓	US ✓	US ✓	TW ✗	VN ✓	5/6
anthropic	ID ✗	JP ✓	VN ✗	ID ✗	CN ✓	US ✗	3/6

핵심 발견: - **단일 LLM은 어느 것도 5/6 이상 hit 안 함** - Anthropic은 mainstream country (US/CN/JP) 선호 — Tirtir JP는 정확이지만 5개 다른 brand 중 3개 miss - OpenAI는 median-best 패턴 자주 surface (Anua/BoJ/Buldak에서 정확 mid-tier 선택) - DeepSeek는 Asian 시장 (Binggrae VN, KGC CN) 강세 - **멀티-LLM ensemble + vote-share priority winner가 단일 LLM 한계 보완해서 6/6 hit**

이는 단일 LLM API 의존하는 경쟁 도구 대비 architectural moat.

4. Production accuracy 측정 인프라 (A3, 2026-06-05 shipped)

위 6/6 hit은 **hindsight 데이터** 한계 명시 disclosure. 진짜 production accuracy는 사용자가 시물 후 실제 launch한 outcome 으로 측정해야 함.

4.1 구축된 corpus 인프라

- **outcome_feedback** 테이블 (live DB 적용 완료)
- 사용자가 ensemble result 페이지에서 "런칭 결과 공유" 클릭 → 모달 → POST

- 제출 시점 시물 recommendation snapshot 자동 저장 (frozen comparison)
- `matched_recommendation` GENERATED column으로 `launch_country == recommendation_country` 자동 판정
- `/admin/outcomes` 에서 hit률, STRONG/MODERATE/WEAK 별 calibration 실시간 표시

4.2 기대 데이터 추세 (paid pilot 가동 후)

시점	누적 outcome	측정 가능한 KPI
M1	~5-10	첫 baseline (noise 큼)
M3	~30	confidence calibration 통계 의미 시작
M6	~100	per-category breakdown
M12	~500	continuous calibration loop, LLM weight tuning 활성화

이 정보가 BD pitch의 두 단계 전략 가능하게 함: 1. 단기 (Q3-Q4 2026): “6/6 hindsight backtest + 정직 limitation disclosure” 2. 중기 (2027 Q1-Q2): “실측 production hit% N% (n=Y)” 데이터로 KPI 정직 upgrade

4.3 한계 + 완화

- **사용자 응답률 의존** — 강제 불가. 응답 incentive (선결제 할인 / outcome 공유 시 보너스 sim 등) 추후 검토
- **Survivorship bias** — 성공 사례 위주 제출 경향. 시스템이 “abandoned” 도 별도 측정해서 양쪽 트래킹
- **N=small 노이즈** — 30+ 모이기 전 hit% 단정 금지. 정직 KPI 발표는 50+ 모인 후 추천

5. 5-step 엔지니어링 progression — 정직 evidence

오늘 (2026-06-04) Tirtir 단일 brand로 진행한 5-step 개선 과정 자체가 시스템의 정직성 + 진화 능력 evidence:

v0.2-A: brandStrategy 입력 채널 추가 → Tirtir: US 100% STRONG (잘못된 자신감, 정답=JP) → 발견: 입력만으로는 부족, anchor 차원 신호 필요
v0.2-B: per-country KOL ecosystem Tavily anchor → Tirtir: KR 67% MODERATE → 발견: origin (KR) bug – LLM이 origin 추천 를 위반
v0.2-C: Aggregator origin filter → Tirtir: US 100% STRONG → 발견: false confidence (top-3 hit 기준이 너무 관대)
v0.2-D: Confidence = top-1 vote share → Tirtir: US 0% WEAK → 발견: WEAK 정직 신호 ✓, 그러나 winner 자체가 polarizing top 아닌 mid-tier collapse
v0.2-E: Vote-share priority winner picker → Tirtir: JP 67% STRONG ✓ 첫 정답 hit → 6 brand 일반화 검증 → 6/6 hit

각 step에서 발견된 결함을 다음 step이 해결. 5번의 시도 모두 정직 metric 으로 측정 → 완전한 audit trail. 이는 마케팅 claim (“저희 시스템은 정확합니다”) 과 다른 차원의 신뢰 기반.

6. 비교 — 대안 도구 대비 차별점

도구/접근	데이터 source	LLM 의존성	정직성 신호	한국 D2C 특화
전통 수출 컨설팅 (KOTRA·중진공)	거시 통계 + 인터뷰	없음	인간 판단 (애매)	✓
Statista / Euromonitor 리포트	산업 통계	없음	제공 안 함	X (글로벌)
GPT/Claude 단독 prompt	학습 데이터	단일	없음	X
Salesforce Einstein / 글로벌 BI	자사 데이터	단일/없음	비공개	X
Market Twin	거시 + brand-strategy + KOL ecosystem 종합	멀티-LLM (3개) + ensemble	STRONG/MODERATE/WEAK 3-tier	✓ (K-수출 anchor)

차별점 요약: 1. 한국 정부·민간 anchor (Comtrade KR 관점, UNI-PASS, DART, KOTRA registry) 자체 통합 2. 멀티-LLM ensemble의 본질적 필요성 backtest로 증명 3. 정직성 신호 (WEAK 도 valuable) 가 시스템 핵심 가치 4. 사용자 brand-context 입력 channel + outcome corpus loop

7. 한계 + 정직 disclosure (BD-pitch 시 반드시 언급)

한계 1 — Hindsight bias 완전 제거 못 함

- **asOfDate** 인프라는 4 anchor (Comtrade/WorldBank/UNI-PASS/DART) 만 지원
- Hofstede/MFDS/KOTRA/Tavily는 latest 데이터 — 일부 hindsight 영향
- brandStrategy 입력은 2026년 시점에서 작성한 vintage description — 작성자 retrospective 영향 가능
- 완전 제거하려면 contemporaneous 자료 (당시 신문·보도·SEC filing) 만 source 사용해야 함, 향후 검증 보강 필요

한계 2 — N=1 per brand

- 같은 brand 재시물 시 LLM stochastic variance로 결과 변동 가능
- 통계적 KPI 신뢰도 위해 brand × 3-5 sim 재실행 필요 (~\$140 추가, 미진행)
- 6/6 hit률은 N=1 corpus 기준의 best-case interpretation

한계 3 — 카테고리 cover 제한

- 4 카테고리 (Beauty/Food/Wellness/Beverage) 검증
- 미검증 카테고리: 전자·의류·뷰티 외 화장품·B2B 산업재 등
- paid pilot 사용자가 다양한 카테고리 가져오면 추가 evidence 형성

한계 4 — Real customer data 없음

- 위 6 brand 모두 자체 backtest, 실제 고객이 시물을 한 결과 아님
- A3 outcome corpus 인프라로 향후 측정 시작

이런 한계를 명시하는 것이 over-claim 보다 강한 신뢰 (특히 B2B 결재 승인 시).

8. Paid Pilot 가입 시 사용자 경험

8.1 가격 (확정, 2026-06-05 기준)

Tier	월 KRW	시물 횟수/월	주요 특징
Free trial	₩0	1 (7일)	hypothesis 1회 체험
Starter	₩500,000	5 hypothesis	1 seat
Validator	₩1,500,000	10 hypothesis + 3 decision	3 seat + cross-project compare
Growth	₩3,500,000	20 (mix)	5 seat + audit logs + API
Enterprise	협의	unlimited	SSO + 전담 지원

(annual 결제 시 17% off)

8.2 결제 + 컴플라이언스

- **현재 가동 통화: KRW** (Toss Payments 단독) — paid pilot 첫 달 KR 사용자 우선
- 통신판매업 신고 완료 (제2026-용인수지-2253호)
- 자동결제 7일 사전 안내 cron + PG사·결제대행사 정보 공개 + 해지 절차 가입과 동일 단계 — 전자상거래법 6항목 모두 충족
- USD 결제 (Stripe) 는 Q4 2026 / 2027 검토 (paid pilot 매출 패턴 보고 결정)

8.3 첫 시물 절차

1. /signup → 워크스페이스 생성 (1분)
 2. 프로젝트 생성: 제품·카테고리·후보국 입력 (5분)
 3. (옵션) brand-strategy 힌트 입력 — Founder/Channel/KOL (3분)
 4. Hypothesis tier 실행 → 결과 받기 (15-25분)
 5. 결과 페이지에서 STRONG/MODERATE/WEAK 추천 + per-LLM 분석 확인
 6. 실제 launch 후 “런칭 결과 공유” 클릭 → corpus 기여
-

9. 추후 로드맵

단기 (2026 Q3)

- Paid pilot 가동 → outcome corpus 첫 30건 모으기
- B6 (이 문서) BD evidence pack 으로 영업 시작
- Stripe USD 가입 시도 (병행, 글로벌 사용자 inbound 대비)

중기 (2026 Q4 ~ 2027 Q1)

- Outcome corpus 50-100건 → 실측 hit% KPI 발표
- Per-LLM × per-category weight tuning (PHASE_F2 활성화)
- Decision tier (6 sim) 사용 패턴 분석 → tier 가격·한도 조정
- ISMS-P/ISO 27001/SOC 2 중 1개 취득 (시장 우선순위 따라)

장기 (2027 Q2+)

- 챌린지 2026 (과기정통부) 참여 데이터 통합
 - 카테고리 cover 확장 (전자·의류·B2B 산업재)
 - 글로벌 사용자 inbound 시 Stripe/Paddle 결정
-

10. 검증 + 재현 정보

10.1 Code references (모두 GitHub 공개 — markettwin/market-twin)

- v0.2-A brandStrategy: commit [541eec2](#)

- v0.2-B KOL ecosystem anchor: commit [a6ee8f6](#)
- v0.2-C origin filter: commit [59cef13](#)
- v0.2-D top-1 vote share: commit [1d63a20](#)
- v0.2-E vote-share priority winner: commit [3eb1c17](#)
- 6-brand backtest commit + PDF: [ca36ced](#)
- A3 outcome feedback corpus: commit [030eed0](#)
- prefetch shared pipeline (drift fix): commit [a6ee8f6](#)

10.2 Project + Ensemble IDs (workspace [0c8e774f-...](#))

Brand	Project ID	as-of
Anua	a8f5ac18	2021-12-31
Tirtir	cf64330c	2020-06-30
BoJ	9ab0eaf8	2021-12-31
Buldak	0b1339c0	2018-12-31
KGC	f03f74dc	2020-12-31
Binggrae	11a59903	2017-03-31

10.3 관련 문서

- [proposals/K-Beauty-D2C-Benchmark-Methodology-v3.pdf](#) — 어제 baseline 3-brand 자세한 방법론
- [proposals/v0.2-A-BrandStrategy-Backtest-Report.pdf](#) — v0.2-A 측정 시점 정직 reframe
- [proposals/v0.2-E-Multi-Category-Generalization-Report.pdf](#) — 6-brand 종합 (이 문서의 기술 detail)
- [proposals/Billing-Activation-Userside-Guide.pdf](#) — Toss 단독 가동 절차 (영업 시 paid pilot 준비)

10.4 BD 영업 시 자주 받는 질문 + 답변

Q: 6/6 hit이 좀 의심스러운데 (마케팅 cherry-pick 아닌가)? A: 모든 backtest 코드 + 결과 데이터 + 시물 ID public commit 으로 audit 가능. 5-step 진화 과정 (Tirtir CN→US→KR→US→US→JP) 자체가 정직 측정 trail. 한계 disclosure (7장) 도 명시.

Q: 우리 카테고리는 검증 안 된 (B2B 산업재 / 의류 / 등)? A: 맞음. 첫 30일 paid pilot 사용 시 본인 카테고리 데이터 outcome 으로 ROI 직접 측정 후 확장 결정 권장. 가격은 Validator 월 ₩1.5M 부담 적정.

Q: 단일 LLM (Claude API 직접) 대비 차별점? A: backtest 결과 단일 LLM 어느 것도 5/6 이상 hit 안 됨. anthropic만으로는 3/6. 멀티-LLM ensemble + vote-share priority가 6/6 만든 architecture moat.

Q: 실제 production 사용한 결과는? A: 현재 미수집 (paid pilot 가동 전). A3 outcome corpus 인프라 운영 중, M3 시점 30건 모이면 실측 hit% 발표. 그 시점까지는 honest "hindsight 6/6, real outcome 측정 중" framing.

Q: 환불 정책? A: 한국 전자상거래법 준수. 첫 30일 unconditional 전액 환불. /refund 페이지에 명시.

11. CTA — 다음 단계

paid pilot 검토 의향 시:

1. **무료 hypothesis 1회 체험** — 본인 카테고리 brand 1개로 시스템 직접 검증 (~25분)
2. **Validator (1.5M/월) 1개월 시범** — 10 hypothesis + 3 decision 으로 본인 의사결정 case 직접 측정
3. **outcome corpus 기여** — 실제 launch 후 결과 공유 → 시스템 정확도 향상에 데이터 기여, 다음 갱신 시 우대

문의: hwlee197874@gmail.com (주)미스터에이아이)

작성: Market Twin / Mr.AI (Claude Opus 4.7) — 2026-06-05 문서 audit: 모든 commit 해시 GitHub 공개.
시물 결과 데이터 본 워크스페이스 (0c8e774f) admin/outcomes 페이지에서 raw access 가능.